

Multi-band NMF: 距離バンド分解による結合非負値行列分解が バルクHi-Cからの細胞型特異的TAD構造の 直接抽出を可能にする

Koki Tsuyuzaki

2026-05-20

要旨

バルクHi-Cデータから細胞型特異的なトポロジカルドメイン（TAD）構造を計算論的に分離することは未解決の課題である。非負値行列分解（NMF）はHi-Cのdeconvolutionに有効だが、前処理としてのO/E正規化がTAD構造を不可逆的に消失させるという根本的なジレンマが存在する。本研究では、Hi-Cコンタクトマトリクスをゲノム距離ごとのバンドに分解し、バンド間で混合係数行列Hを共有する **Multi-band NMF**を提案する。この手法は距離減衰の除去とTAD構造の保持を初めて両立させ、マウス胸腺上皮細胞（mTEC）のAire遺伝子座に細胞型特異的なコンパクトTAD（～1Mb）をバルクデータから直接抽出することに成功した。

はじめに

染色体コンフォメーションキャプチャー（Hi-C）はゲノムの三次元構造を網羅的に捉える強力な技術であり、TAD、コンパートメント、ループといった階層的な構造単位の解明に貢献してきた（Lieberman-Aiden et al., 2009; Dixon et al., 2012; Rao et al., 2014）。しかし、ほとんどのHi-Cデータは細胞集団のバルク測定から得られるため、観測されるコンタクトマトリクスは混合組織中の複数細胞型のシグナルの重ね合わせである。

NMFはこの混合シグナルの分離（deconvolution）に適した手法であり、Hi-Cデータへの適用が試みられてきた。NMFの入力として最も一般的な前処理はO/E（Observed/Expected）正規化であり、これはゲノム距離に依存するコンタクト頻度の指数関数的減衰（距離減衰）を除去する。距離減衰はデータの分散の大部分を支配するため、これを除去しなければNMFの基底は距離減衰パターンのみを学習してしまう。

ところがO/E正規化には重大な副作用がある。TADの実体は対角近傍における局所的なコンタクトの濃縮——すなわち距離減衰からの正の逸脱——であるため、距離減衰の除去はTADシグナルの大部分を同時に消失させる。実際、本研究でO/E NMF（K=8）の全コンポーネントからcooltools insulation scoreでTAD境界検出を試みたところ、**検出されたTAD境界は0個**であった（図1上段）。

このジレンマ——距離減衰を除去しなければdeconvolutionが成立せず、除去すればTAD構造が消失する——は、NMFに基づくHi-C解析の根本的な限界とみなされてきた。

本研究ではこのジレンマに対し、距離減衰とTAD構造の情報が異なるスケールに存在するという洞察に基づく解決策を提案する。距離減衰はゲノム距離バンド間のスケール差として現れるのに対し、TAD構造は各バンド内の空間パターンとして存在する。この分離可能性を利用し、Hi-Cコンタクトマトリクスをゲノム距離ごとのバンドに分解した上で、バンド間で混合係数行列Hを共有する結合NMF（Multi-band NMF）を構築した。

方法

データ

マウス（mm10）由来の複数細胞型バルクHi-Cデータを100kb解像度で使用した。計15サンプル、常染色体（chr1-19）のみを対象とした。

- 胸腺細胞: 4D Nucleome Consortiumより11種 (DN, DP, CD4 SP, CD8 SP, Treg前駆体, 成熟Treg等の胸腺T細胞分化ステージ)
- 胸腺髄質上皮細胞 (mTEC): GSE180937由来、SRA fastqからnf-core/hicで再処理した ICEバランス済みコンタクトマトリクス
- 脳神経細胞 (対照群): Bonev et al. (2017) GSE96107より3種 (ES細胞, 神経前駆細胞NPC, 皮質神経細胞CN)

性染色体 (chrX, chrY) はサンプル間のカバレッジ差が大きく、ICEバランシングでも除去しきれない十字アーティファクトをNMF基底に生じるため除外した (性染色体除外により mTECのloading: 0.540 → 0.870)。

特徴量の構築

各サンプルのICEバランス済みコンタクトマトリクスから、ゲノム距離5Mb以内 (50 bin) の全bin対 (i, j) のコンタクト値を抽出し、 $N = 1,232,364$ 次元の特徴ベクトルを構築した。各特徴量にはゲノム距離 $d = j - i \in \{0, 1, \dots, 50\}$ が付随する。

Multi-band NMF

バンド分解. 特徴量をゲノム距離 d ごとに51バンドに分割する。各バンド d の特徴量行列を $\mathbf{X}_d \in \mathbb{R}_{\geq 0}^{n_d \times M}$ (n_d : バンド d の特徴量数、 $M = 15$: サンプル数) とする。

モデル. 各バンドを以下のように分解する:

$$\mathbf{X}_d \approx \mathbf{W}_d \mathbf{H} \quad (d = 0, 1, \dots, 50)$$

ここで $\mathbf{W}_d \in \mathbb{R}_{\geq 0}^{n_d \times K}$ はバンドごとに独立な基底行列、 $\mathbf{H} \in \mathbb{R}_{\geq 0}^{K \times M}$ は**全バンドで共有**される混合係数行列である。 $K = 8$ とした。

この定式化の核心は、「サンプルの細胞型組成はゲノム距離によらず一定である」という生物学的に自然な仮定にある。Hの共有により、全51バンドのデータが協調的に細胞型分離を制約する一方、バンドごとに独立な $\mathbf{W}_d$ が各距離スケールに固有の空間パターン (TAD、コンパートメント等) を自由に表現できる。

前処理. 各バンド内で各サンプルの合計が1となるよう L1正規化を行った:

$$\mathbf{X}_d^{(\text{norm})}[:, m] = \frac{\mathbf{X}_d[:, m]}{\|\mathbf{X}_d[:, m]\|_1}$$

この正規化により 距離バンド間のスケール差 (= 距離減衰) が等化される。一方、バンド内の空間パターン (どのbin対のコンタクトが相対的に強い) は保持される。これが距離減衰の除去と TAD構造の保持を両立する鍵である。

最適化. Multiplicative Update (MU) 則に基づき 500イテレーション更新した:

$$\begin{aligned} \mathbf{W}_d &\leftarrow \mathbf{W}_d \odot \frac{\mathbf{X}_d \mathbf{H}^\top}{\mathbf{W}_d \mathbf{H} \mathbf{H}^\top + \epsilon} \\ \mathbf{H} &\leftarrow \mathbf{H} \odot \frac{\sum_d \mathbf{W}_d^\top \mathbf{X}_d}{(\sum_d \mathbf{W}_d^\top \mathbf{W}_d) \mathbf{H} + \epsilon} \end{aligned}$$

H更新式は全バンドの勾配を集約する形となり、これが結合NMFの本質である。 $\epsilon = 10^{-10}$ 、乱数シード42で初期化した。

TAD境界検出

各コンポーネント k の W_d を全バンドにわたって結合し、対称コンタクトマトリクスを染色体ごとに再構成して.cool形式に変換した後、cooltools insulation score（窓サイズ500kb, ignore_diags=2）でTAD境界を検出した。

O/E NMFとの比較

ベースライン手法として、O/E正規化後の全特徴量を単一行列としてNMF分解した（同一K=8、500イテレーション）。O/E NMFについてはin-silico mixing検証（fold-in法: Wを固定しHのみMU更新）も実施し、混合比率推定精度を評価した。

結果

O/E NMFは細胞型を分離するがTAD構造を消失させる

O/E NMF（K=8）は細胞型の分離に有効であった。mTECはcomp4にloading 0.903で明確に単独分離され、thymocyte各分化ステージ、brain各ステージもそれぞれ異なるコンポーネントに対応した。

in-silico mixing検証でも、異なる系統間の2成分混合（5ペア）で Pearson $r \geq 0.990$ 、RMSE 0.042–0.134を達成した（図1）。近縁細胞型ペアである CD4 SP対Tregでも $r = 0.999$ と極めて正確に分離可能であった。3成分混合（DN + CD4 SP + Brain ES）でも $r \geq 0.976$ であった。

しかし、O/E NMFの全8コンポーネントからコンタクトマトリクスを再構成し insulation scoreを計算したところ、**検出されたTAD境界は全コンポーネントで0個**であった（図2）。O/E正規化により対角近傍のコンタクト値が平坦化された結果、insulation scoreの計算に必要な局所コントラストが完全に失われていた。

Multi-band NMFはTAD構造を保持したまま細胞型を分離する

Multi-band NMF（K=8、autosome限定）のコンタクトマップを図3に示す。O/E NMF（図2）とは対照的に、対角近傍にTADに対応する明瞭な三角形パターンが全コンポーネントにわたって保持されている。

細胞型分離. mTECはcomp1にloading 0.870で分離された。thymocyte系（DN: comp7に0.855、CD4 SP: comp3に0.941）、brain系（comp6に0.913）もそれぞれ明確に分離された。

TAD境界の定量的評価

comp1（mTEC基底）から1,299個のTAD境界が検出された。mTEC実測バルクHi-Cから検出したリファレンス境界（1,484個）との比較結果を表1に示す。

表1. Multi-band NMF TAD境界の リファレンスとの一致度

comp	対応細胞型	境界数	Jaccard	Recall	Prec.	Ins. r
1	mTEC	1,299	0.601	0.799	0.912	0.865
7	DN	1,179	0.168	0.507	0.639	0.577
3	CD4 SP	1,120	0.140	0.439	0.581	0.543
6	Brain	430	0.006	0.026	0.088	-0.065

Recall/Precisionは ± 1 bin（100kb）の許容幅での評価。Ins. r はinsulation profileの全染色体平均Pearson相関。

comp1はリファレンスTAD境界の**80%を ± 1 bin以内で回収**し（recall = 0.799）、検出された境界の**91%がリファレンスと一致**した（precision = 0.912）。insulation profileの全染色体平均相関も0.865と高く、TAD構造が定量的に保持されていることが確認された。

一方、thymocyte系コンポーネント（comp3, 7）のmTECリファレンスとのrecallは44–51%と、constitutive TAD（細胞型間で保存される境界、約60%と推定）の分だけ部分的に一致した。Brain（comp6）はmTECと全く異なるTADパターンを示し（insulation相関 -0.065）、Multi-band NMFが細胞型特異的なTAD構造を分離できていることの間接的な証拠となった。




Figure 1: 図1. O/E NMFのin-silico mixing検証。上段: 2成分混合6ペア（真の比率 vs fold-in推定比率）。中段: 近縁・同一コンポーネントペア。下段: 3成分混合。対角線は完全一致を表す。異系統間ペアでは $r > 0.99$ の高精度で混合比率を回収できるが、同一コンポーネントに縮約されるペア（Brain ES vs CN）では分離不可能であった。




Figure 2: 図2. O/E NMFコンポーネントのコンタクトマップ。3つのゲノム領域（上段: Aire遺伝子座 chr10:17–27Mb、中段: chr1:50–70Mb、下段: chr6:50–65Mb）×全8コンポーネント。各コンポーネントの最上位サンプル名を表示。O/E正規化により対角近傍のシグナルが平坦化され、TADに相当する三角形パターンは完全に消失している。




Figure 3: 図3. Multi-band NMFコンポーネントのコンタクトマップ（autosome限定）。同一ゲノム領域・同一カラースケールでO/E NMF（図2）と比較。対角近傍にTAD様の三角形パターンが保持されつつ、各コンポーネントが異なる細胞型に対応する空間パターンを示す。comp1: mTEC、comp3: CD4 SP、comp6: Brain、comp7: DN。

リファレンスHi-Cとの視覚的比較

図4にmTEC、Brain ES、DN thymocyteの実測バルクHi-CコンタクトマップとTAD境界（青線）を示す。これらはMulti-band NMFへの入力データの一部であり、NMFが分離すべき「正解」のパターンに相当する。




Figure 4: 図4. リファレンスバルクHi-Cコンタクトマップ。左列: mTEC、中央: Brain ES、右列: DN thymocyte。青線がcooltools insulation scoreによるTAD境界。上段: Aire遺伝子座 (chr10:17-27Mb)、中段: chr1:50-70Mb、下段: chr6:50-65Mb。細胞型間でTADパターンが明確に異なることが確認できる。

Insulation profileの細胞型間比較

図5にmTEC、Brain ES、DN thymocyteのinsulation profile (log2 insulation score) を3領域について重ねて示す。

Aire遺伝子座の細胞型特異的TAD

Multi-band NMFの生物学的妥当性を検証するため、胸腺髄質上皮細胞の機能に中心的な役割を果たすAire遺伝子 (chr10:21.9Mb, mm10) 周辺のTAD構造を細胞型間で比較した。




Figure 5: 図5. Insulation profileの細胞型間比較。赤: mTEC、緑: Brain ES、青: DN thymocyte。三角マーカーがTAD境界。上段: Aire遺伝子座 (chr10:17-27Mb)、中段: chr1:50-70Mb、下段: chr6:50-65Mb。mTECとDN thymocyteは多くの境界を共有するが (constitutive TAD)、profileの振幅やピーク位置に細胞型特異的な差異がある。BrainはAire座位周辺でmTECと全く異なるパターンを示す。

Aireは胸腺髄質上皮細胞（mTEC^{hi}）において数千の組織特異抗原（TRA）遺伝子の無差別的転写（promiscuous gene expression）を誘導する転写因子であり、中枢性免疫寛容の確立に不可欠である（Anderson et al., 2002; Mathis & Benoist, 2009）。近年、この転写制御に Aire座位周辺の三次元ゲノム構造が関与することが報告されている（Guha et al., 2017; Teixeira et al., 2021）。

表2. Aire遺伝子座を含むTADの比較

ソース	TAD範囲	サイズ
comp1 (mTEC NMF基底)	21.2–22.3 Mb	1.1 Mb
mTEC リファレンス	21.3–22.1 Mb	0.8 Mb
comp7 (DN thymocyte)	21.4–23.7 Mb	2.3 Mb
comp6 (Brain)	検出なし	—

comp1 (mTEC基底) から推定された Aire含有TADは21.2–22.3Mb (1.1Mb) であり、mTECリファレンスの21.3–22.1Mb (0.8Mb) と高い一致を示した。

注目すべきは細胞型間の差異である。DN thymocyteでは同領域のTADが21.4–23.7Mb (2.3Mb) と mTEC の約2倍広く、Aire周辺の絶縁（insulation）が弱いことが示唆された。Brainではこのゲノム領域に TAD 構造がほとんど検出されなかった。

mTECにおける比較的コンパクトな Aire含有TAD（～1Mb）は、Aire遺伝子の発現制御に関与するクロマチンドメインを反映している可能性がある。Aireはスーパーエンハンサーを介してゲノム上に分散するTRA遺伝子群の転写を活性化するが（Guha et al., 2017）、Aire自身の座位を取り囲むコンパクトなTAD構造は、このマスター転写因子の発現制御における空間的な制約条件を示唆している。Multi-band NMFがバルクHi-Cの混合シグナルからこのmTEC特異的なTAD構造を分離できたことは、本手法の生物学的妥当性を強く支持する。

考察

距離減衰とTAD構造の分離可能性

Multi-band NMFは、Hi-Cデータに固有の距離減衰構造を明示的にモデリングすることで、従来のO/E NMFでは不可能であったTAD構造の保持と細胞型分離の両立を実現した。

本手法の鍵は、距離減衰とTAD構造が異なる「軸」に情報を持つという構造的洞察にある。距離減衰はバンド間のスケール差（ $d=1$ のバンドは $d=50$ の数十倍の値を持つ）として現れるが、TAD構造はバンド内の空間パターン（特定のbin対が同一バンド内で相対的に高い値を持つ）として存在する。per-band L1正規化は前者を等化し、後者を保持する——これはO/E正規化のように個々のbin対レベルで期待値からの逸脱を計算する操作とは本質的に異なる。

モデルの構造と仮定

H共有制約「サンプルの細胞型組成はゲノム距離によらない」は生物学的に自然な仮定である。同一サンプルのバルクHi-Cにおいて、近接コンタクト（ $d=1$ ）と遠距離コンタクト（ $d=50$ ）の細胞型混合比が異なるとすれば、それは測定アーティファクトを意味する。この仮定のもと、51バンドのデータが協調的にHを制約するため、少数サンプル（ $M=15$ ）でも安定した細胞型分離が可能となる。

性染色体アーティファクトの除去

chrX/chrYのサンプル間カバレッジ差は、NMF基底に十字状のアーティファクトを生じさせ、mTECのloading（0.540 → 0.870）に大きな影響を及ぼした。この問題はICEバランシングでは解消されず、常染色体への限定が有効であった。ヒトデータへの適用ではchrXの除外のみで十分と考えられるが、サンプルの性別構成を事前に確認すべきである。

計算コストとスケーラビリティ

現在の実装はPython (numpy) の スクラッチ実装であり、100kb解像度・15サンプルで数分、25kb (～2,200万特徴量) で約47分、10kb (～1.2億特徴量) で約5時間と 見積もられる。MU更新はバンドごとに 独立に 実行可能であるため、memmap + バンド逐次処理により メモリ制約下でも10kb解像度まで 対応可能である。大規模な結合NMF専用ライブラリやGPUは現時点では不要であり、手法の実装障壁は極めて低い。

今後の展開

本研究の結果は、Multi-band NMFが リファレンスパネルを必要としない (reference-free) Hi-C deconvolution手法として 有望であることを示す。TADパターンそのものがコンポーネントの 生物学的解釈を与えるため、既知の細胞型参照データに依存しない。これはヒト臨床検体など 参照データの入手が困難な場面で 特に有用である。

今後の展開として以下が挙げられる:

1. **高解像度検証:** 25kb解像度でのTAD境界精度、10kb解像度でのAire座位ループレベル解析
2. **Fold-in解析:** mTECバルクHi-Cに対する fold-inによるmTEC亜集団 (Aire-stage, pre-Aire, post-Aire等) の推定
3. **大規模コホート:** 数十～数百サンプルの ヒト組織Hi-Cアトラスへの適用
4. **他のエピゲノムデータとの統合:** ChIP-seq、ATAC-seqとの結合解析による TAD構造の機能的解釈

参考文献

- Anderson MS et al. (2002) Science 298: 1395–1401.
- Bonev B et al. (2017) Cell 171: 557–572.
- Dixon JR et al. (2012) Nature 485: 376–380.
- Guha TK et al. (2017) Cell Rep 20: 604–612.
- Lee DD & Seung HS (1999) Nature 401: 788–791.
- Lieberman-Aiden E et al. (2009) Science 326: 289–293.
- Mathis D & Benoist C (2009) Annu Rev Immunol 27: 287–312.
- Rao SSP et al. (2014) Cell 159: 1665–1680.
- Teixeira V et al. (2021) Nat Commun 12: 6049.